Pipelines de Dados Tabulares, Datasets e Modelagem Multitarefa

Aula 03 — Ingestão de Dados, Prevenção de Data Leakage, Classificação & Regressão no PyTorch

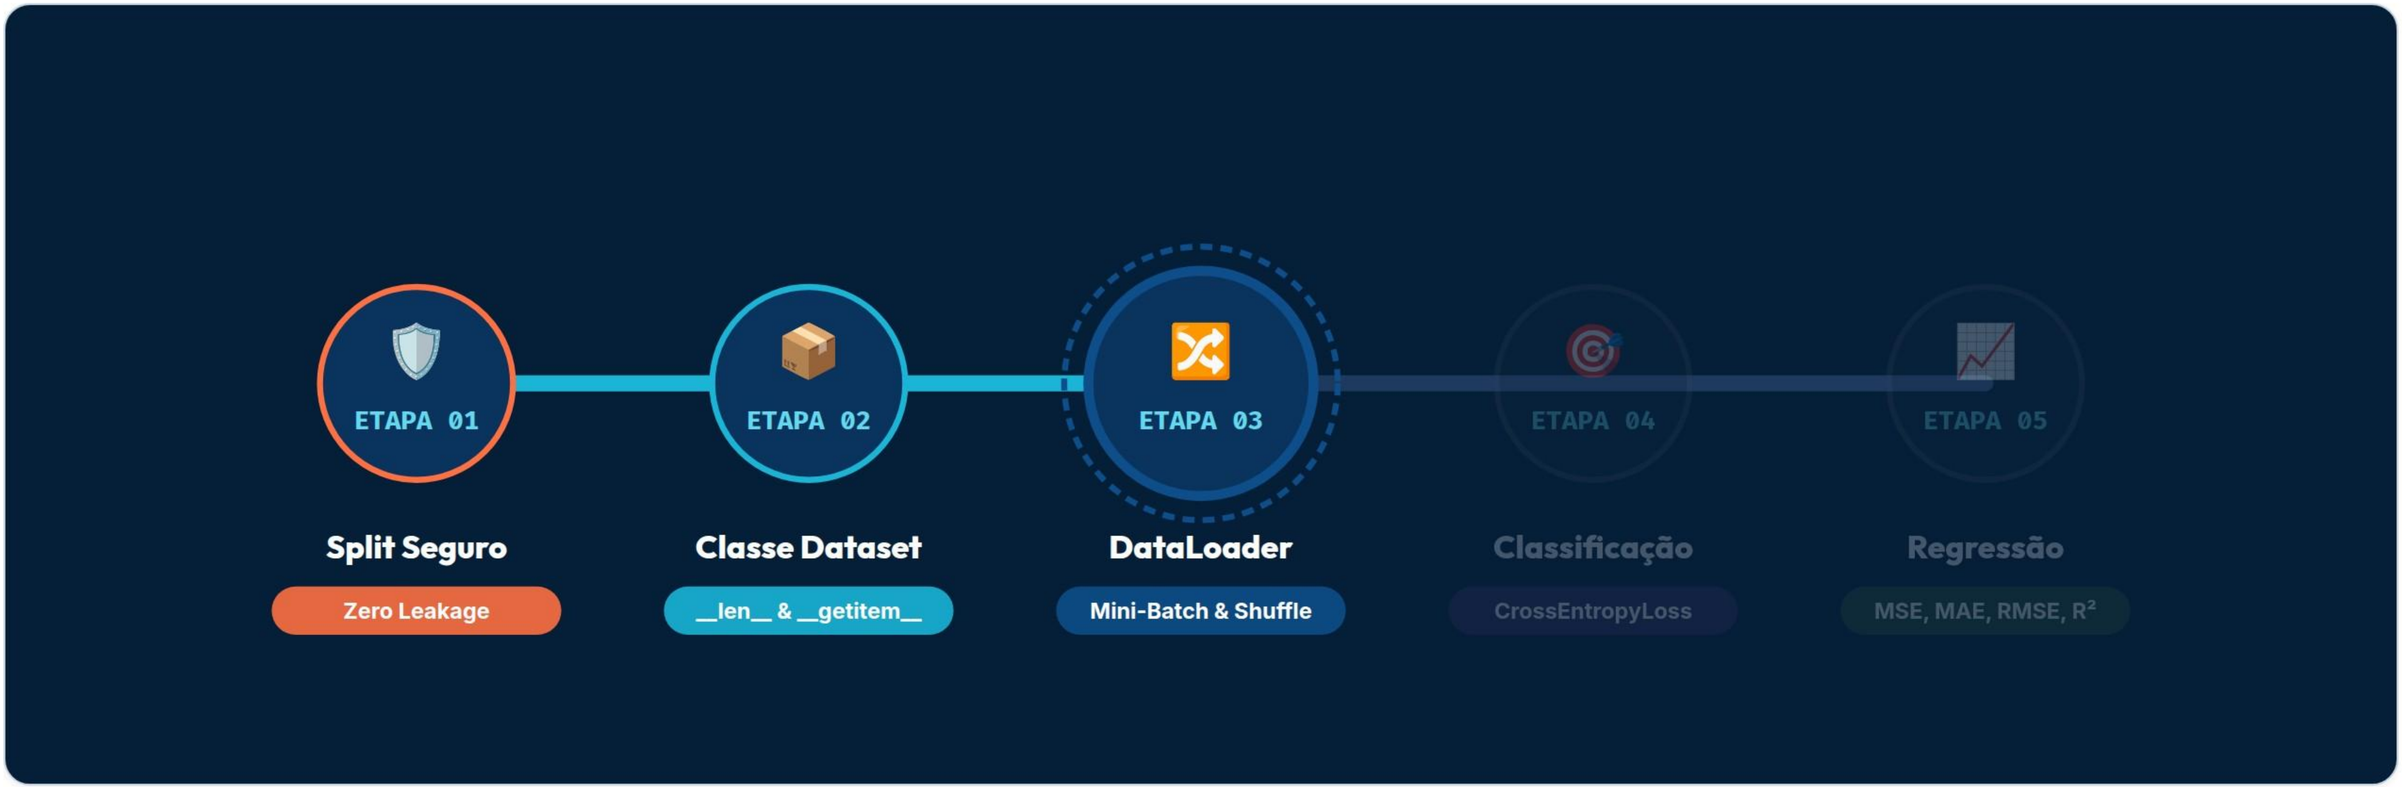
Instrutor: **Prof. Allan Spadini**

Redes Neurais Profundas | Graduação Faculdade Infnet

Roteiro & Objetivos da Aula

Cinco etapas visuais para dominar pipelines supervisionados

✓. Split Seguro | ✓. Classe Dataset | 3. DataLoader | 4. Classificação | 5. Regressão | ▶ Avançar Etapa

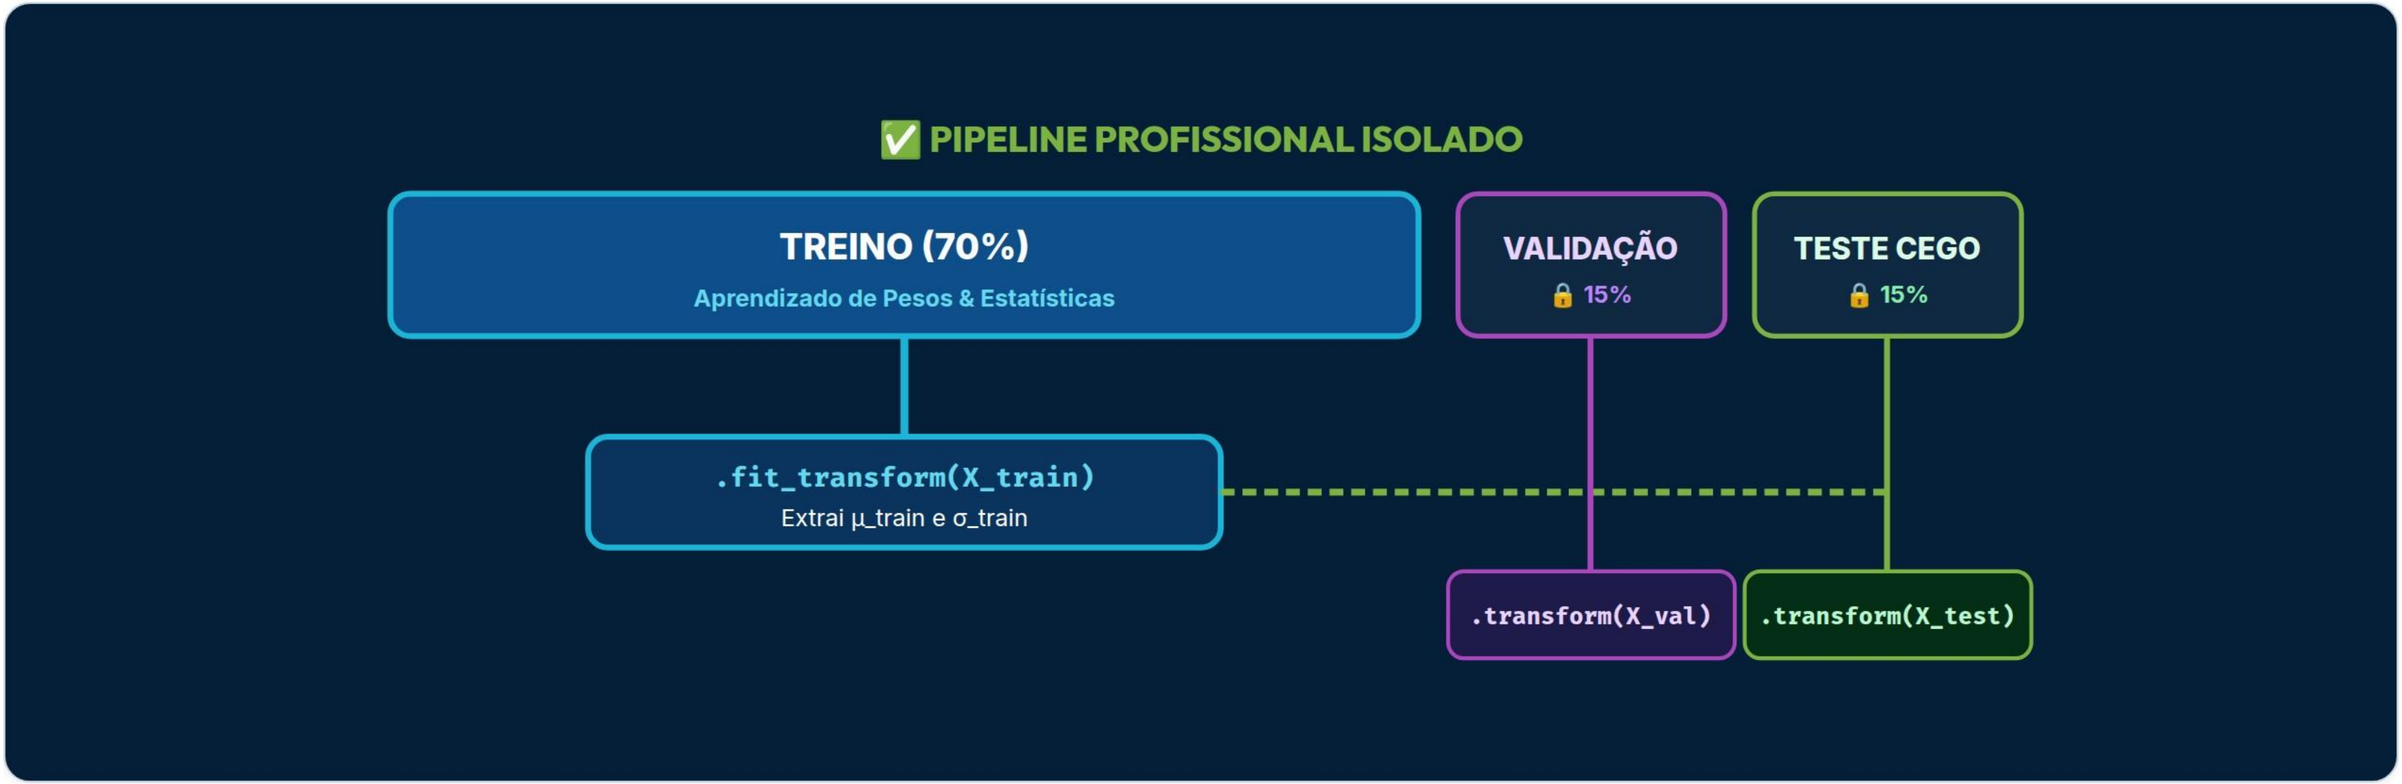


ETAPA 03 Fatiamento em lotes estocásticos para alimentar a GPU sem estourar memória.

A Regra de Ouro do Particionamento

Isolamento estatístico passo a passo entre Treino, Validação e Teste

✓. 1. Erro: Fit Antes do Split | ✓. 2. Correto: Split 70/15/15 Primeiro | 3. 3. Fit no Treino → Transform | ↺ Reiniciar



PASSO 2 PASSO 2 CORRETO: Ajustar (.fit_transform) só no Treino e aplicar (.transform) nos demais.

Simulador Visual: Detecção de Data Leakage

Construa a distribuição normalizada com vs. sem vazamento de dados

⚠️ Com Data Leakage | ✅ Isolado (Sem Leakage)

1. Amostras no Eixo ($) | 2. Cálculo de μ e σ | 3. Teste vs Produção Real

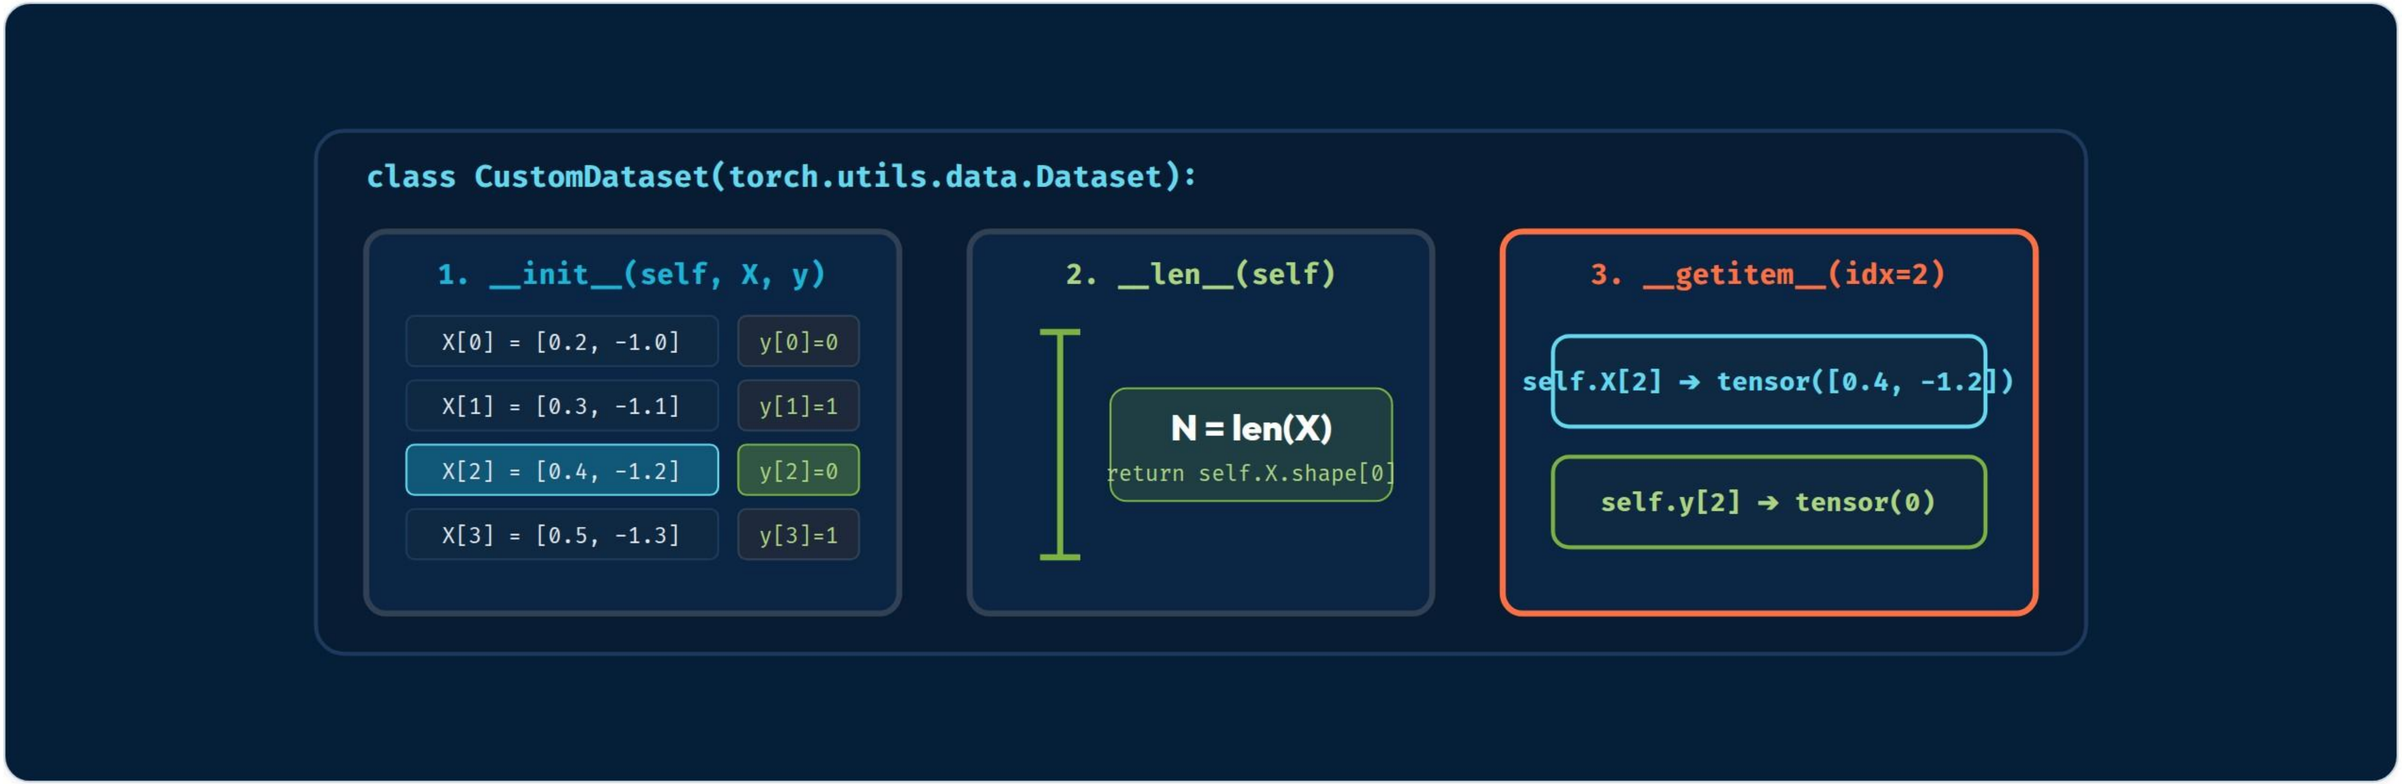


⚠️ Com vazamento: a curva de normalização enxerga os extremos do teste e cria falsa acurácia.

Anatomia da Classe Dataset no PyTorch

Os 3 métodos fundamentais construídos passo a passo

✓. 1. __init__(self, X, y) | ✓. 2. __len__(self) | 3. 3. __getitem__(self, idx) | ↺ Reiniciar

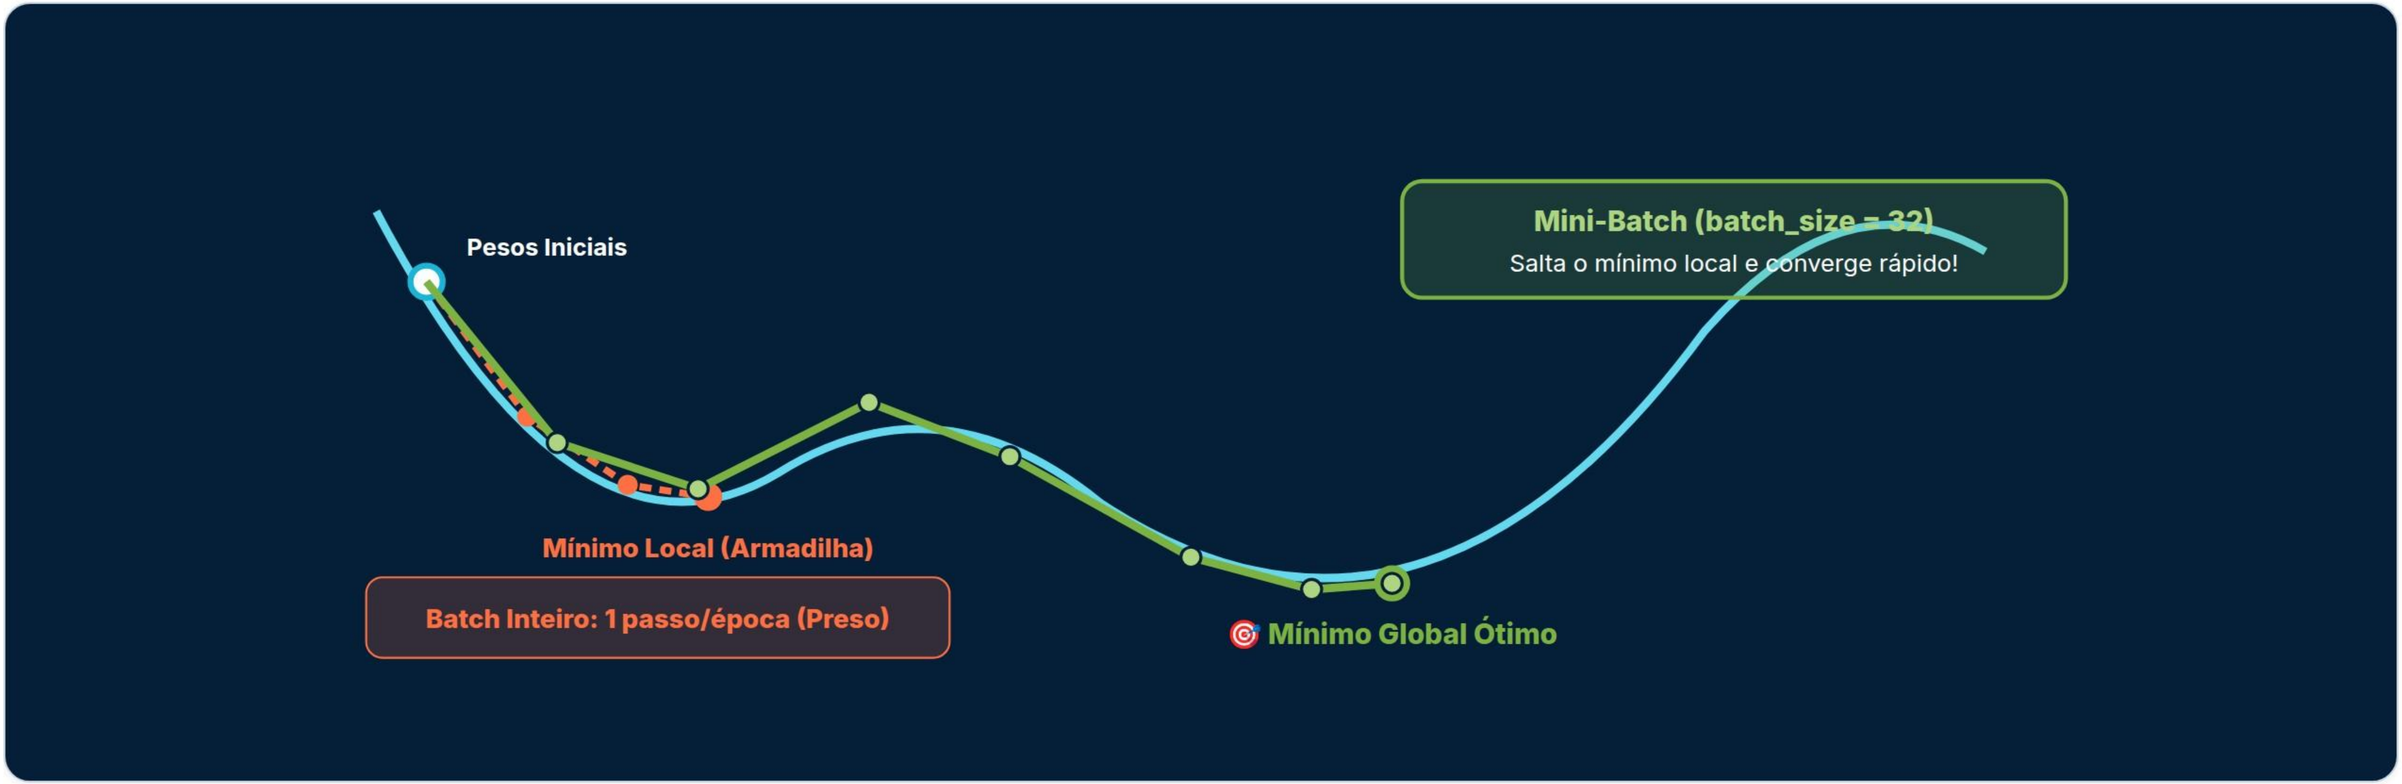


MÉTODO 3 Busca pelo índice idx e entrega o par (X[idx], y[idx]) sob demanda.

O Papel Estratégico do DataLoader

Trajetória de otimização: Batch Completo vs. Mini-Batch SGD

✓. 1. Superfície de Erro (Loss) | ✓. 2. Batch Completo (Lento/Preso) | 3. 3. Mini-Batch DataLoader (Ágil) | ↺ Reiniciar



ETAPA 3 O DataLoader divide em mini-batches: atualiza dezenas de vezes por época e o ruído estocástico escapa de armadilhas!

Visualizador Interativo: O Efeito do Shuffle

Composição dos mini-batches e estabilidade do vetor gradiente

■ Classe 0 (Azul) ■ Classe 1 (Laranja)

✅ shuffle=True | 🔄 Sortear Época #1



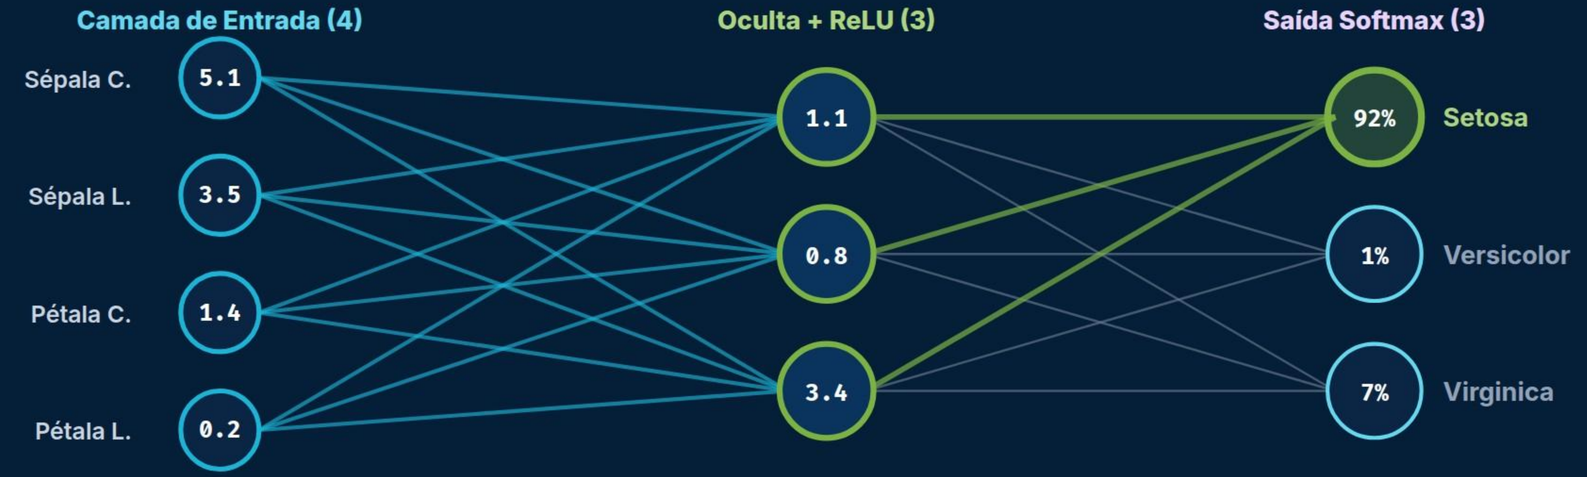
✨ shuffle=True: Lotes misturados mantêm o vetor gradiente apontando de forma estável para o mínimo global.

Simulador do Forward Pass Tabular

Propagação camada por camada no Dataset Iris

Iris Setosa | Iris Versicolor | Iris Virginica

1. Entradas (X) | 2. Oculta (ReLU) | 3. Saída (Logits/Probs)

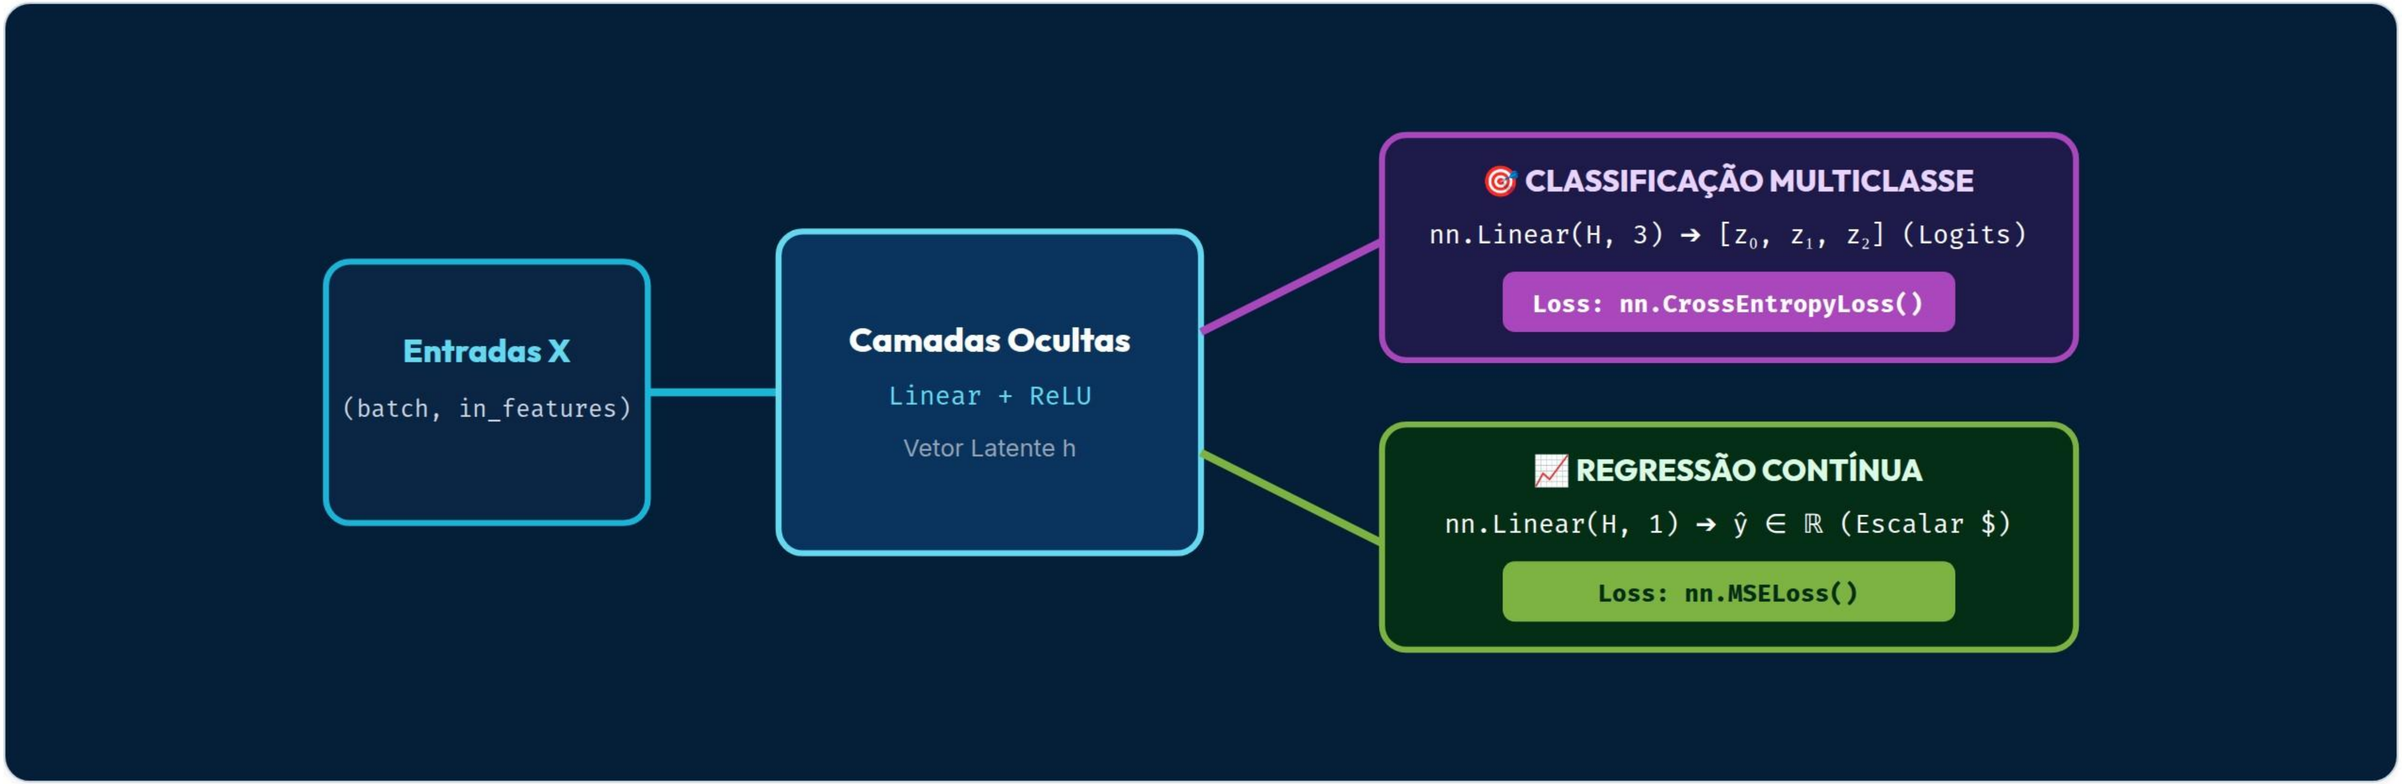


Passo 3: A camada de saída gera os logits para as 3 espécies (Alvo real: Iris Setosa).

Classificação vs. Regressão em PyTorch

Mesmo tronco extrator, diferentes cabeças de saída e funções de perda

✓. 1. Extrator Comum (MLP) | ✓. 2. Cabeça de Classificação (3 Classes) | 3. 3. Cabeça de Regressão (1 Valor) | ↺ Reiniciar

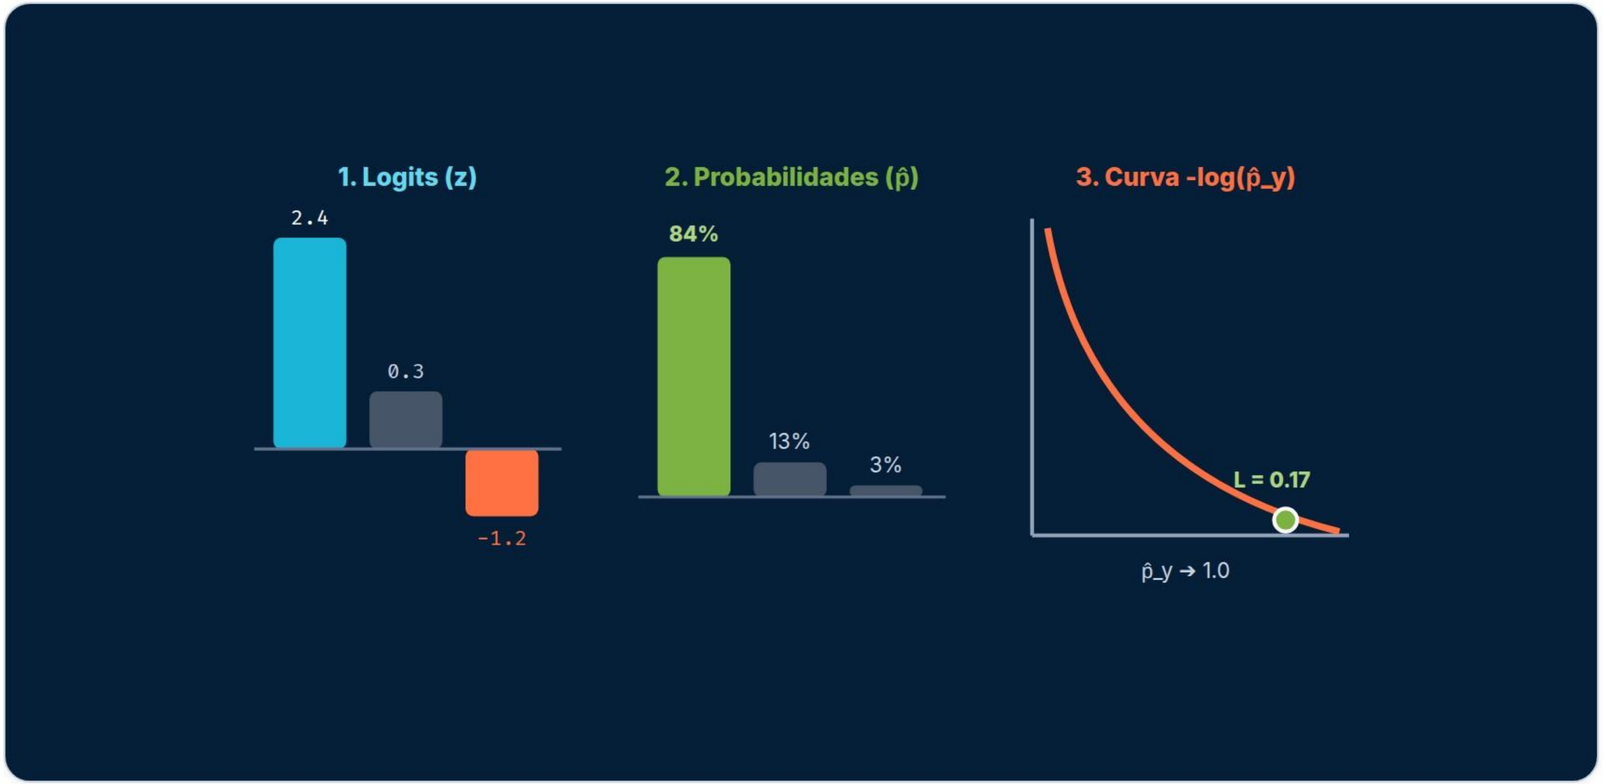


ARQUITETURA 3 Regressão: Camada final nn.Linear(H, 1) emite 1 escalar contínuo ($) avaliado por nn.MSELoss().

A Matemática Visual da Entropia Cruzada

De Logits brutos à penalidade logarítmica sem Softmax explícito

✓. 1. Logits Brutos (z) | ✓. 2. Softmax Interno (p̂) | 3. 3. Penalidade -log(p̂_y) | ↺ Reiniciar



$$\mathcal{L}_{CE} = -\log\left(\frac{e^{z_y}}{\sum_j e^{z_j}}\right)$$

z_y : Logit da classe real

Sem Softmax explícito na rede

Log-Sum-Exp evita overflow

PASSO 3 A perda penaliza logaritmicamente quando a probabilidade da classe correta (c=0) é baixa.

Modelando Regressão: O Caso do Seguro Saúde

Atributos de entrada (X) e assimetria de cauda longa nos custos ($)

✓. 1. Atributos Biométricos (X) | ✓. 2. Assimetria de Custos ($) | 3. 3. Efeito Fumante + BMI | ↺ Reiniciar

Entradas Tabulares (X)

🎂 Idade	18 a 64 anos
⚖️ BMI (IMC)	16.0 a 53.1
👶 Dependentes	0 a 5 filhos
🚬 Smoker	yes / no (One-Hot)

Distribuição do Alvo Contínuo: Custos Médicos ($)

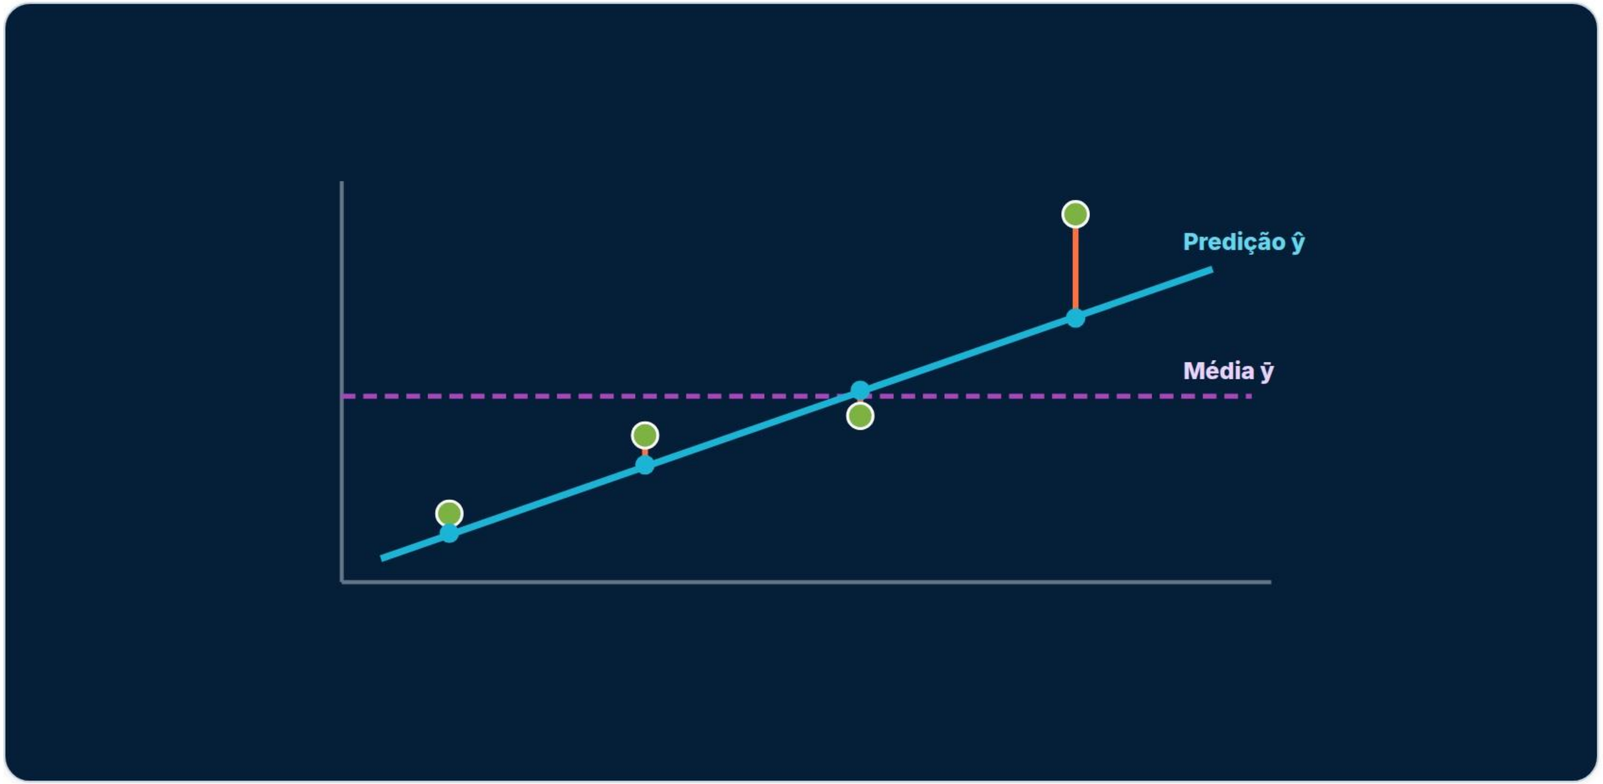


ETAPA 3 Pacientes fumantes com IMC elevado concentram os custos extremos na cauda direita.

Métricas Essenciais de Regressão

Construção geométrica de MAE, RMSE e Coeficiente R^2

✓. 1. MAE (Erro Absoluto) | ✓. 2. RMSE (Penaliza Outliers) | 3. 3. R^2 (Variância Explicada) | ↺ Reiniciar



$$R^2 = 1 - \frac{\sum(y_i - \hat{y}_i)^2}{\sum(y_i - \bar{y})^2}$$

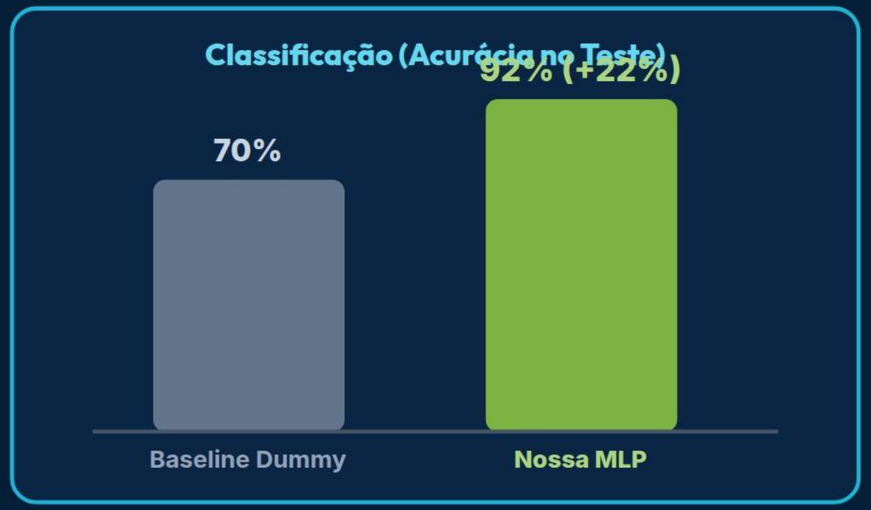
- Ponto Verde: Valor Real (y)
- Reta Azul: Predição da MLP (ŷ)
- Segmento Laranja: Resíduo (Erro)

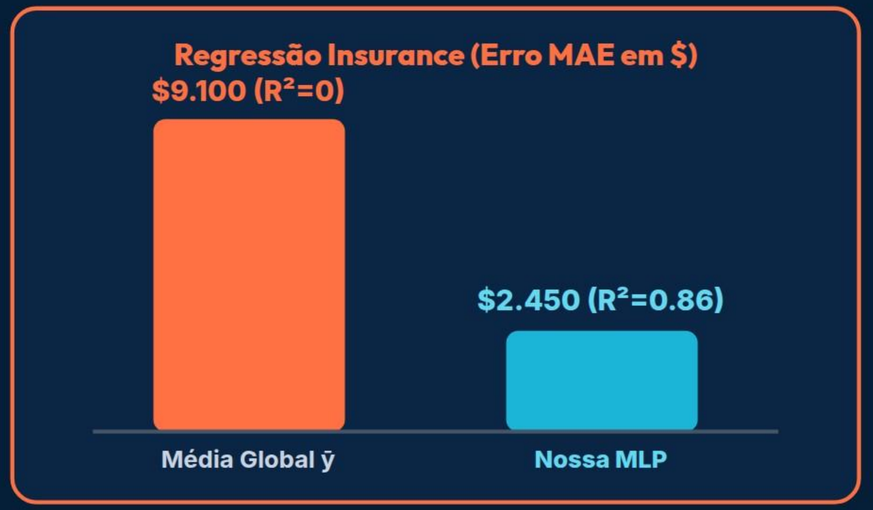
R^2 R^2 compara o erro da nossa rede com a linha horizontal da média simples (ȳ).

A Necessidade de Baselines Não-Triviais

Comprovando visualmente que a rede neural superou o chute ingênuo

✓. 1. Classificação: Chute Majoritário | ✓. 2. Regressão: Chute na Média (R^2=0) | 3. 3. Ganho Real da Rede Neural | ↺ Reiniciar





ETAPA 3 A MLP só comprova aprendizado quando supera com folga o baseline não-trivial no Teste Cego.

Quiz de Fixação: Pipelines & Modelagem Tabular

Valide seu domínio sobre Data Leakage, DataLoaders e Funções de Perda

❓ **Quiz de Fixação: Questão 1 de 4**

Pontuação: 0 / 4

1. O que ocorre se aplicarmos o StandardScaler ANTES da divisão train_test_split?

A) Vazamento de Dados (Data Leakage), pois as estatísticas (média/desvio) do teste influenciam o treino.

B) O treinamento fica mais rápido, pois o scaler é executado uma única vez.

C) O modelo aprende melhor, pois vê a distribuição real inteira.

D) O PyTorch dispara um erro de runtime ao criar o DataLoader.

Síntese da Aula & Conexão com o Projeto 1

Fluxo completo de engenharia de dados e validação no PyTorch

✓. 1. Split Estratificado | ✓. 2. Fit Só no Treino | 3. 3. Dataset & DataLoader | 4. 4. Métricas vs Baseline | ▶ Avançar Etapa



CHECKLIST 3/4 Empacotar tensores na classe Dataset e iterar em mini-batches estocásticos.

Próximos Passos: Aula 04

Estabilidade de Treinamento: Inicialização, Normalização & Dropout

✓. 1. Inicialização Xavier & He | ✓. 2. BatchNorm & LayerNorm | 3. 3. Regularização com Dropout | ↺ Reiniciar

1. Xavier & Kaiming He



`Var(W) = 2 / n_in`

2. BatchNorm1d / LayerNorm



Estabilidade Interna

3. Inverted Dropout



`nn.Dropout(p=0.3)`

PRÓXIMA AULA Desligamento aleatório de neurônios (Inverted Dropout) para combater o overfitting.