Pipelines de Dados Tabulares, Datasets e Modelagem Multitarefa

Aula 03 — Ingestão de Dados, Prevenção de Data Leakage, Classificação & Regressão no PyTorch

Instrutor: **Prof. Allan Spadini**

Redes Neurais Profundas | Graduação Faculdade Infnet

A Regra de Ouro do Particionamento

Isolamento estatístico passo a passo entre Treino, Validação e Teste

1. 1. Erro: Fit Antes do Split | 2. 2. Correto: Split 70/15/15 Primeiro | 3. 3. Fit no Treino → Transform | ▶ Avançar Etapa



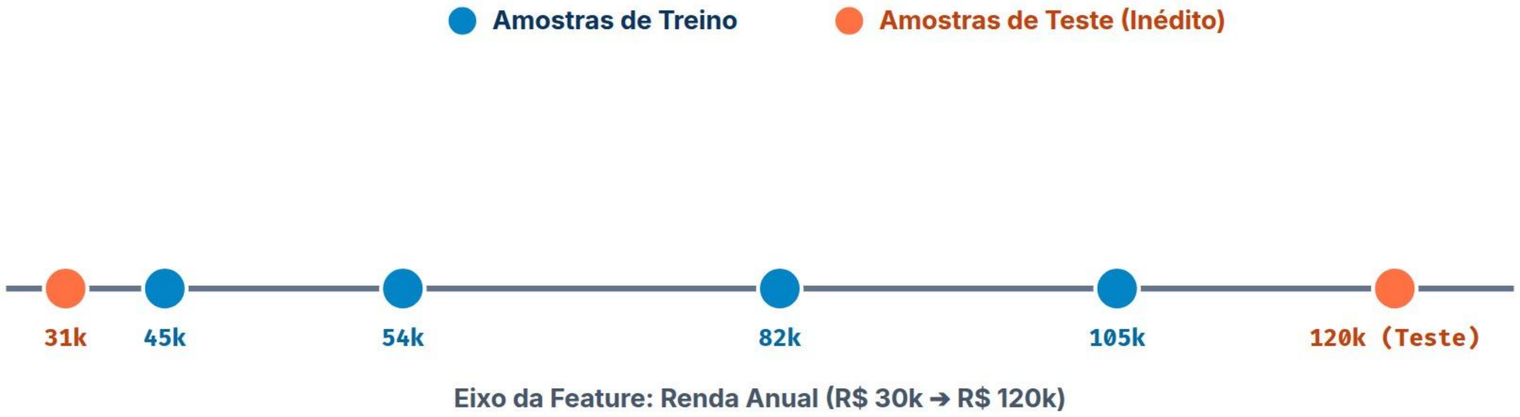
VAZAMENTO ERRADO: Calcular μ e σ no dataset inteiro faz o Teste contaminar o Treino (Data Leakage).

Simulador Visual: Detecção de Data Leakage

Construa a distribuição normalizada com vs. sem vazamento de dados

⚠️ Com Data Leakage | ✅ Isolado (Sem Leakage)

1. Amostras no Eixo ($) | 2. Cálculo de μ e σ | 3. Teste vs Produção Real



⚠️ Com vazamento: a curva de normalização enxerga os extremos do teste e cria falsa acurácia.

Anatomia da Classe Dataset no PyTorch

Os 3 métodos fundamentais construídos passo a passo

1. 1. __init__(self, X, y) | 2. 2. __len__(self) | 3. 3. __getitem__(self, idx) | ▶ Avançar Etapa

```
class CustomDataset(torch.utils.data.Dataset):
```

1. __init__(self, X, y)

X[0] = [0.2, -1.0]	y[0]=0
X[1] = [0.3, -1.1]	y[1]=1
X[2] = [0.4, -1.2]	y[2]=0
X[3] = [0.5, -1.3]	y[3]=1

2. __len__(self)

N = len(X)

return self.X.shape[0]

3. __getitem__(idx=2)

self.X[2] → tensor([0.4, -1.2])

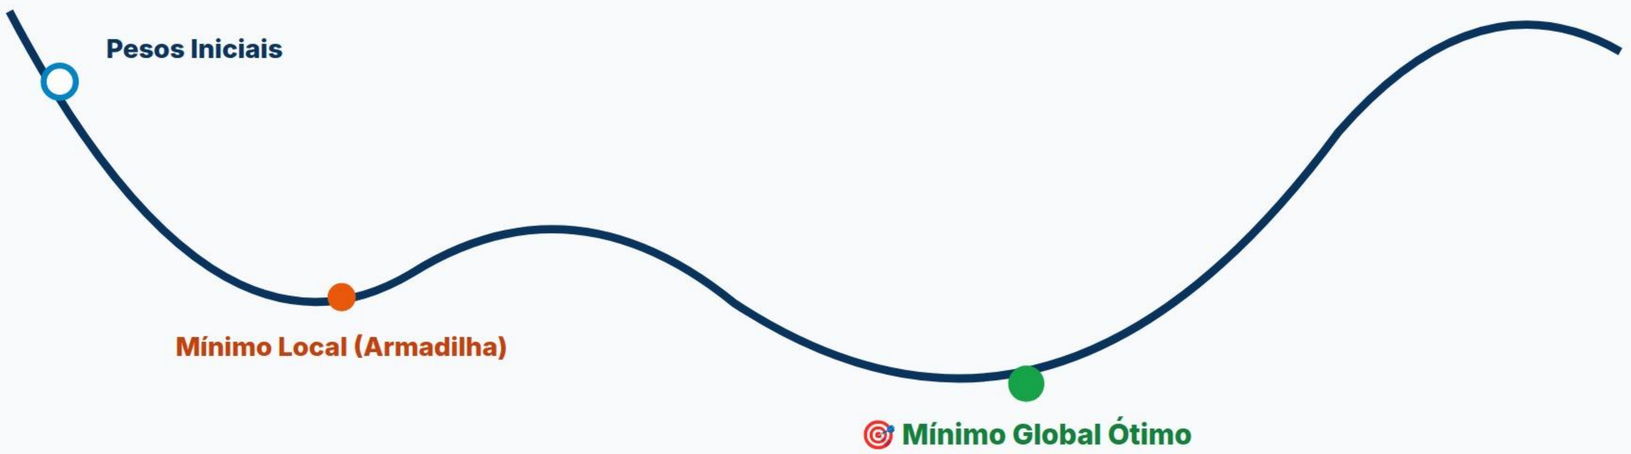
self.y[2] → tensor(0)

MÉTODO 1 Converte arrays em Tensores PyTorch (X: float32, y: long/float32) na memória.

O Papel Estratégico do DataLoader

Trajetória de otimização: Batch Completo vs. Mini-Batch SGD

1. 1. Superfície de Erro (Loss) | 2. 2. Batch Completo (Lento/Preso) | 3. 3. Mini-Batch DataLoader (Ágil) | ▶ Avançar Etapa



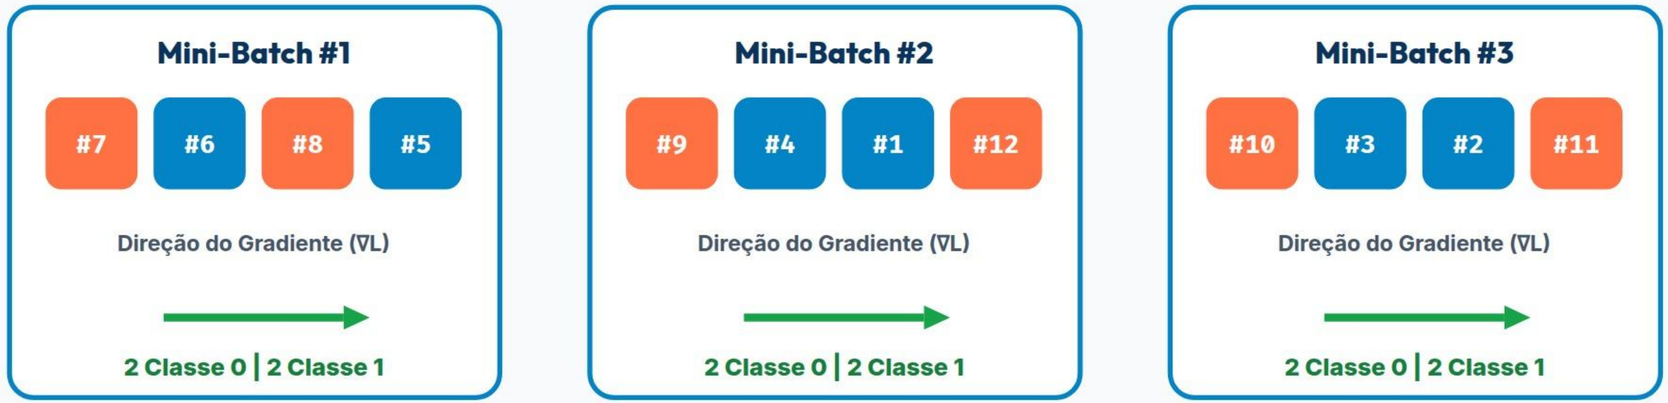
ETAPA 1 A superfície de perda possui vales rasos (mínimos locais) e o mínimo global ótimo.

Visualizador Interativo: O Efeito do Shuffle

Composição dos mini-batches e estabilidade do vetor gradiente

■ Classe 0 (Azul) ■ Classe 1 (Laranja)

✅ shuffle=True | 🔄 Sortear Época #1



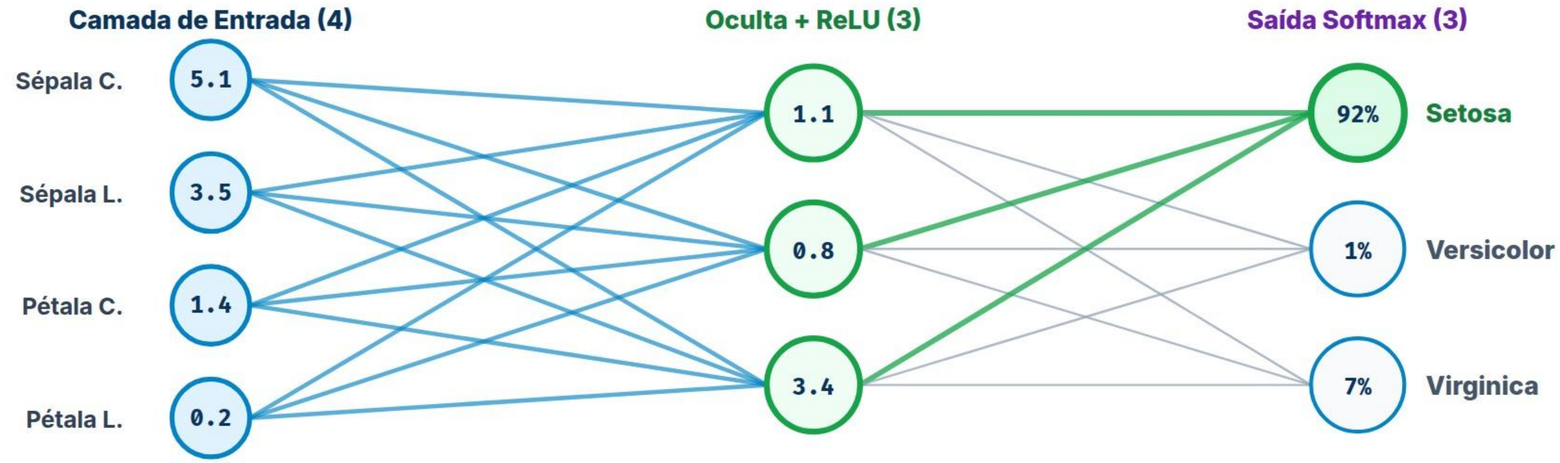
✨ shuffle=True: Lotes misturados mantêm o vetor gradiente apontando de forma estável para o mínimo global.

Simulador do Forward Pass Tabular

Propagação camada por camada no Dataset Iris

🌸 Iris Setosa | 🌸 Iris Versicolor | 🌸 Iris Virginica

1. Entradas (X) | 2. Oculta (ReLU) | 3. Saída (Logits/Probs)



Passo 3: A camada de saída gera os logits para as 3 espécies (Alvo real: Iris Setosa).

Classificação vs. Regressão em PyTorch

Mesmo tronco extrator, diferentes cabeças de saída e funções de perda

1. 1. Extrator Comum (MLP) | 2. 2. Cabeça de Classificação (3 Classes) | 3. 3. Cabeça de Regressão (1 Valor) | ▶ Avançar Etapa



ARQUITETURA 1 O tronco oculto da MLP transforma os atributos tabulares X em representações não-lineares h.

A Matemática Visual da Entropia Cruzada

De Logits brutos à penalidade logarítmica sem Softmax explícito

1. 1. Logits Brutos (z) | 2. 2. Softmax Interno (p̂) | 3. 3. Penalidade -log(p̂_y) | ▶ Avançar Etapa



$$\mathcal{L}_{CE} = -\log\left(\frac{e^{z_y}}{\sum_j e^{z_j}}\right)$$

z_y : Logit da classe real

Sem Softmax explícito na rede

Log-Sum-Exp evita overflow

PASSO 1 A última camada nn.Linear entrega Logits brutos (sem Softmax manual na rede!).

Modelando Regressão: O Caso do Seguro Saúde

Atributos de entrada (X) e assimetria de cauda longa nos custos ($)

1. 1. Atributos Biométricos (X) | 2. 2. Assimetria de Custos ($) | 3. 3. Efeito Fumante + BMI | ▶ Avançar Etapa

Entradas Tabulares (X)

🎂 Idade	18 a 64 anos
⚖️ BMI (IMC)	16.0 a 53.1
👶 Dependentes	0 a 5 filhos
🚬 Smoker	yes / no (One-Hot)

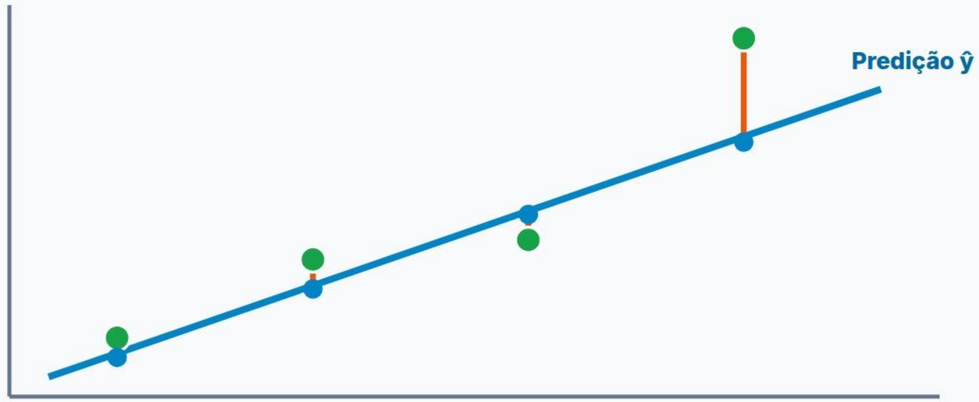


ETAPA 1 Variáveis de entrada X: Idade, IMC (BMI), Filhos, Fumante (yes/no) e Região.

Métricas Essenciais de Regressão

Construção geométrica de MAE, RMSE e Coeficiente R^2

1. 1. MAE (Erro Absoluto) | 2. 2. RMSE (Penaliza Outliers) | 3. 3. R^2 (Variância Explicada) | ▶ Avançar Etapa



$$MAE = \frac{1}{N} \sum |y_i - \hat{y}_i|$$

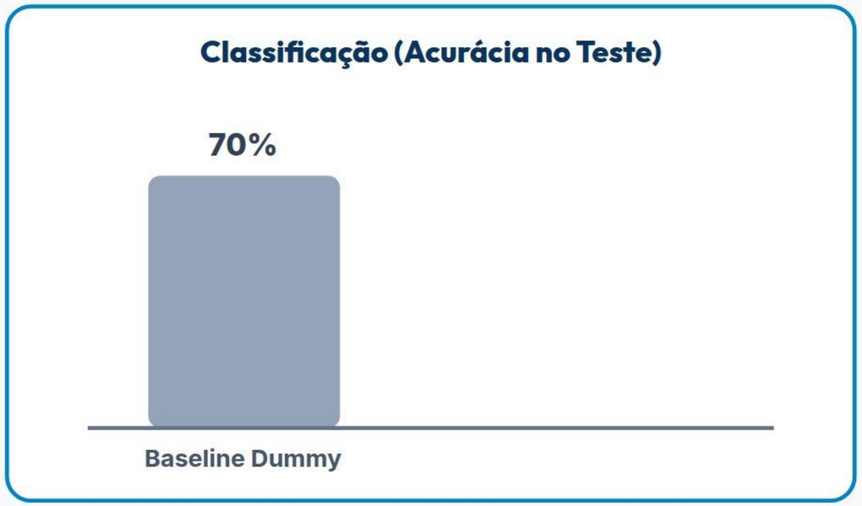
- Ponto Verde: Valor Real (y)
- Reta Azul: Predição da MLP (ŷ)
- Segmento Laranja: Resíduo (Erro)

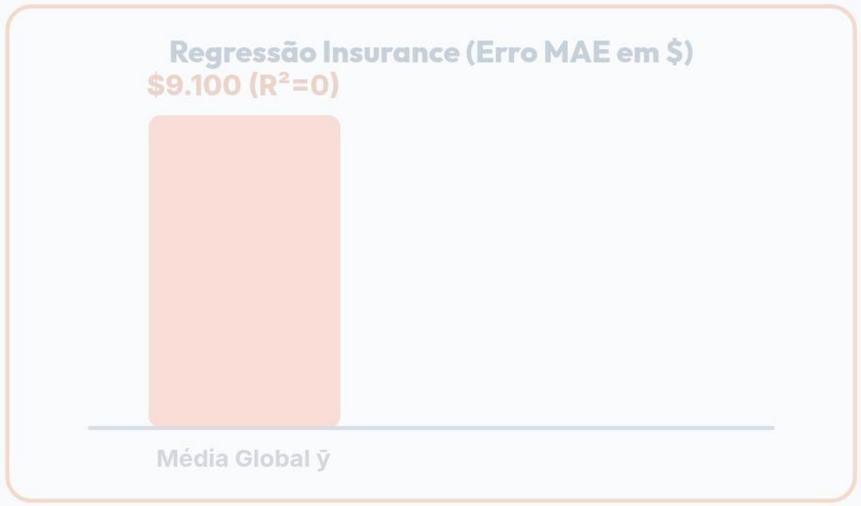
MAE MAE mede a distância vertical média |y - ŷ| diretamente na moeda original ($).

A Necessidade de Baselines Não-Triviais

Comprovando visualmente que a rede neural superou o chute ingênuo

1. 1. Classificação: Chute Majoritário | 2. 2. Regressão: Chute na Média (R^2=0) | 3. 3. Ganho Real da Rede Neural | ▶ Avançar Etapa





ETAPA 1 Se 70% dos clientes pertencem à classe majoritária, um modelo cego atinge 70% de acurácia sem aprender nada!

Quiz de Fixação: Pipelines & Modelagem Tabular

Valide seu domínio sobre Data Leakage, DataLoaders e Funções de Perda

❓ **Questão 1 de 4**

Pontuação: 0 / 4

1. O que ocorre se aplicarmos o StandardScaler ANTES da divisão train_test_split?

A) Vazamento de Dados (Data Leakage), pois a média e o desvio do teste contaminam o treino.

B) O treinamento fica mais estável, pois usa a distribuição completa.

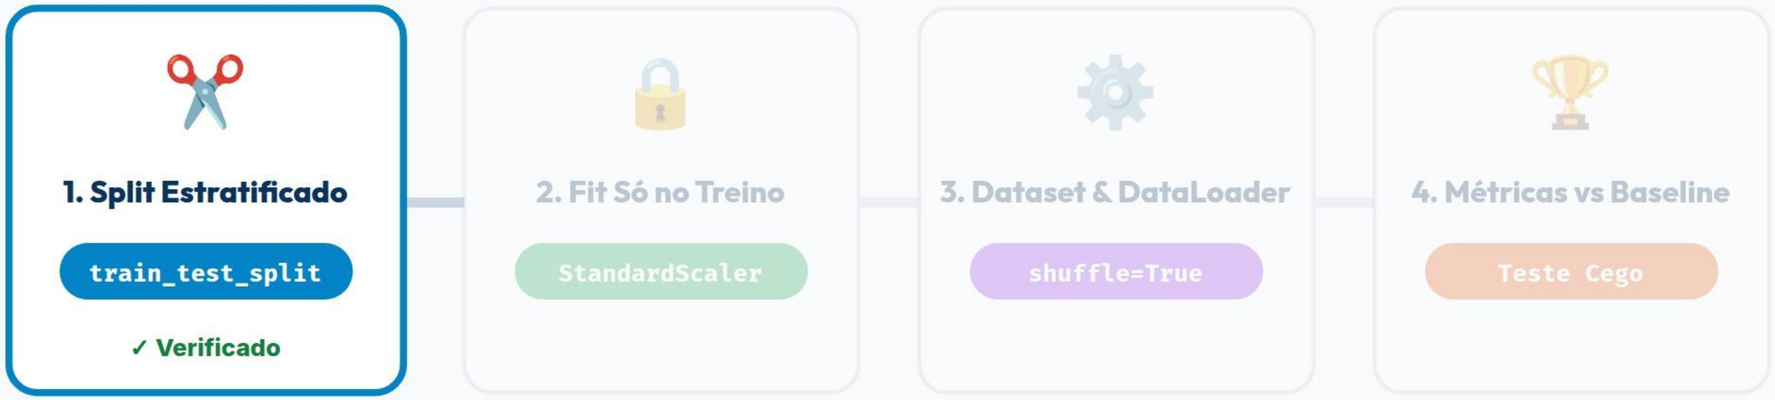
C) O PyTorch bloqueia a criação do DataLoader.

D) Não há impacto algum nas métricas de produção.

Síntese da Aula & Conexão com o Projeto 1

Fluxo completo de engenharia de dados e validação no PyTorch

1. 1. Split Estratificado | 2. 2. Fit Só no Treino | 3. 3. Dataset & DataLoader | 4. 4. Métricas vs Baseline | ▶ Avançar Etapa



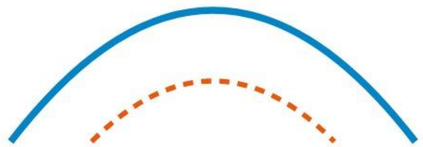
CHECKLIST 1/4 Dividir Treino (70%), Validação (15%) e Teste (15%) antes de qualquer estatística.

Próximos Passos: Aula 04

Estabilidade de Treinamento: Inicialização, Normalização & Dropout

1. 1. Inicialização Xavier & He | 2. 2. BatchNorm & LayerNorm | 3. 3. Regularização com Dropout | ▶ Avançar Etapa

1. Xavier & Kaiming He



`Var(W) = 2 / n_in`

2. BatchNorm1d / LayerNorm



Estabilidade Interna

3. Inverted Dropout



`nn.Dropout(p=0.3)`

PRÓXIMA AULA Aula 04: Como calibrar a variância inicial dos pesos para evitar explosão ou sumiço do gradiente.